

PRACTICA 2

Jaime Lorenzo Sánchez

18 de abril de 2022

Índice general

1. Introducción	1
2. Ejercicio 1	2
3. Ejercicio 2	3
3.1. Emotions dataset	3
3.2. Birds dataset	4
3.3. scene dataset	5
4. Ejercicio 3	7
4.1. Emotions dataset	7
4.2. Birds dataset	8
4.3. Scene dataset	8
5. Ejercicio 5	10
5.1. Resultados de entrenamiento	10
5.2. Resultados de test	15

Capítulo 1

Introducción

En esta práctica se va a estudiar el funcionamiento de los diferentes métodos implementados y se presenta como trabajo opcional la programación de un método multi-etiqueta no presente en scikit-multilearn.

Los problemas multi-etiqueta elegidos pertenecen a la biblioteca skmultilearn. Dichos problemas a utilizar en la práctica son los siguientes:

- emotion
- delicious
- medical

El código de implementación utilizado es python3.

Para poder utilizar Scikit-multilearn, primero debemos instalarlo mediante el siguiente comando: `sudo pip3 install scikit-multilearn`

Para poder ejecutar el ejemplo `ml.py`, debemos instalar el paquete `arff` mediante el siguiente comando: `sudo pip3 install arff`

Capítulo 2

Ejercicio 1

Elija tres métricas de las estudiadas en teoría para evaluar el rendimiento de los métodos. Una al menos de esas medidas ha de ser implementada por el alumno

Las métricas ha utilizar son las siguientes:

- Hamming loss: Se define como la fracción de las etiquetas incorrectas con respecto al número total de etiquetas.
- Accuracy score: Se define como la relación entre los verdaderos positivos y los verdaderos negativos con todas las observaciones positivas y negativas.
- F1-Score-Micro: Se utiliza para evaluar la calidad de los problemas binarios multi-etiqueta

Capítulo 3

Ejercicio 2

En primer lugar vamos a comparar el efecto en el rendimiento de los métodos de transformación de la elección del clasificador base. Ejecute el método BR con tres clasificadores base de los disponibles en scikit-learn y compare el rendimiento en los problemas seleccionados usando las tres métricas del apartado anterior

3.1. Emotions dataset

Se ha realizado un total de 391 entrenamientos y 202 tests.

Para poder obtener un buen estudio, se ha utilizado el método BR con Regresión Logística con un máximo de 10000 iteraciones.

Aplicado dicho método para cada dataset, se han obtenido las siguientes métricas:

	Logistic Regression	SVC	DecisionTreeClassifier
Hamming loss	0.217	0.325	0.279
Accuracy score	0.257	0.014	0.134
F1-micro	0.631	0.075	0.562

Cuadro 3.1: EmotionsDataset

Si observamos la tabla, podemos realizar las siguientes conclusiones para el problema

utilizado:

- El clasificador Logistic Regression ha obtenido una menor fracción de etiquetas incorrectas con respecto al número total de etiquetas, seguido por el clasificador DecisionTreeClassifier y el clasificador SVC. Por tanto, el clasificador Logistic Regression ha cometido el menor número de errores en el entrenamiento y test de los dataset del problema.
- El clasificador Logistic Regression ha obtenido una mayor relación entre los verdaderos positivos y los verdaderos negativos con todas las observaciones positivas y negativas, seguido por el clasificador DecisionTreeClassifier y el clasificador SVC
- El clasificador SVC ha obtenido una mayor calidad en el problema binario multietiqueta, seguido del clasificador Logistic Regression y DecisionTreeClassifier.

3.2. Birds dataset

Se han realizado un total de 322 entrenamientos y 323 tests

Para poder obtener un buen estudio, se ha utilizado el método BR con Regresión Logística con un máximo de 100000 iteraciones.

Aplicado dicho método para cada dataset, se han obtenido las siguientes métricas:

	Logistic Regression	SVC	DecisionTreeClassifier
Hamming loss	0.061	0.053	0.063
Accuracy score	0.464	0.471	0.384
F1-micro	0.381	0.018	0.423

Cuadro 3.2: birdsDataset

Si observamos la tabla, podemos realizar las siguientes conclusiones para el problema utilizado:

- El clasificador SVC ha obtenido una menor fracción de etiquetas incorrectas con respecto al número total de etiquetas, seguido por el clasificador Logistic Regression

y el clasificador DecisionTreeClassifier. Por tanto, el clasificador SVC ha cometido el menor número de errores en el entrenamiento y test de los dataset del problema.

- El clasificador SVC ha obtenido una mayor relación entre los verdaderos positivos y los verdaderos negativos con todas las observaciones positivas y negativas, seguido por el clasificador Logistic Regression y el clasificador DecisionTreeClassifier
- El clasificador DecisionTreeClassifier ha obtenido una mayor calidad en el problema binario multietiqueta, seguido del clasificador Logistic Regression y el clasificador SVC.

3.3. scene dataset

Se han realizado 1211 entrenamientos y 1196 tests

Para poder obtener un buen estudio, se ha utilizado el método BR con Regresión Logística con un máximo de 10000 iteraciones.

Aplicado dicho método para cada dataset, se han obtenido las siguientes métricas:

	Logistic Regression	SVC	DecisionTreeClassifier
Hamming loss	0.104	0.085	0.156
Accuracy score	0.524	0.587	0.345
F1-micro	0.682	0.725	0.566

Cuadro 3.3: scene

Si observamos la tabla, podemos realizar las siguientes conclusiones para el problema utilizado:

- El clasificador SVC ha obtenido una menor fracción de etiquetas incorrectas con respecto al número total de etiquetas, seguido por el clasificador Logistic Regression y el clasificador DecisionTreeClassifier. Por tanto, el clasificador SVC ha cometido el menor número de errores en el entrenamiento y test de los dataset del problema.
- El clasificador SVC ha obtenido una mayor relación entre los verdaderos positivos y

los verdaderos negativos con todas las observaciones positivas y negativas, seguido por el clasificador Logistic Regression y el clasificador DecisionTreeClassifier

- El clasificador SVC ha obtenido una mayor calidad en el problema binario multi-etiqueta, seguido del clasificador Logistic Regression y el clasificador DecisionTreeClassifier.

Capítulo 4

Ejercicio 3

Seleccione la mejor combinación del ejercicio anterior y compárela con los métodos LP y MLkNN

4.1. Emotions dataset

Se han obtenido los siguientes resultados:

	Logistic Regression	SVC	DecisionTreeClassifier	MLKNN
Hamming loss	0.220	0.450	0.290	0.295
Accuracy score	0.332	0.129	0.208	0.193
F1-micro	0.672	0.270	0.559	0.516

Cuadro 4.1: EmotionsDataset2

Si observamos la tabla, comprobamos lo siguiente:

- El clasificador MLKNN ha cometido el menor número de errores en el entrenamiento y test de los dataset del problema
- El clasificador Logistic Regression ha obtenido una mayor relación entre los verdaderos positivos y los verdaderos negativos con todas las observaciones positivas y negativas.

- El clasificador Logistic Regression ha obtenido una mayor calidad en el problema binario multi-etiqueta

4.2. Birds dataset

Se han obtenido los siguientes resultados:

	Logistic Regression	SVC	DecisionTreeClassifier	MLKNN
Hamming loss	0.062	0.056	0.069	0.062
Accuracy score	0.464	0.477	0.461	0.452
F1-micro	0.354	0.099	0.294	0.132

Cuadro 4.2: BirdssDataset2

Si observamos la tabla, comprobamos lo siguiente:

- El clasificador SVC ha cometido el menor número de errores en el entrenamiento y test de los dataset del problema
- El clasificador SVC ha obtenido una mayor relación entre los verdaderos positivos y los verdaderos negativos con todas las observaciones positivas y negativas.
- El clasificador Logistic Regression ha obtenido una mayor calidad en el problema binario multi-etiqueta

4.3. Scene dataset

Se han obtenido los siguientes resultados:

	Logistic Regression	SVC	DecisionTreeClassifier	MLKNN
Hamming loss	0.095	0.086	0.152	0.102
Accuracy score	0.681	0.708	0.517	0.558
F1-micro	0.729	0.753	0.575	0.685

Cuadro 4.3: SceneDataset3

Si observamos la tabla, comprobamos lo siguiente:


- El clasificador SVC ha cometido el menor número de errores en el entrenamiento y test de los dataset del problema
- El clasificador SVC ha obtenido una mayor relación entre los verdaderos positivos y los verdaderos negativos con todas las observaciones positivas y negativas.
- El clasificador SVC ha obtenido una mayor calidad en el problema binario multi-etiqueta

Capítulo 5

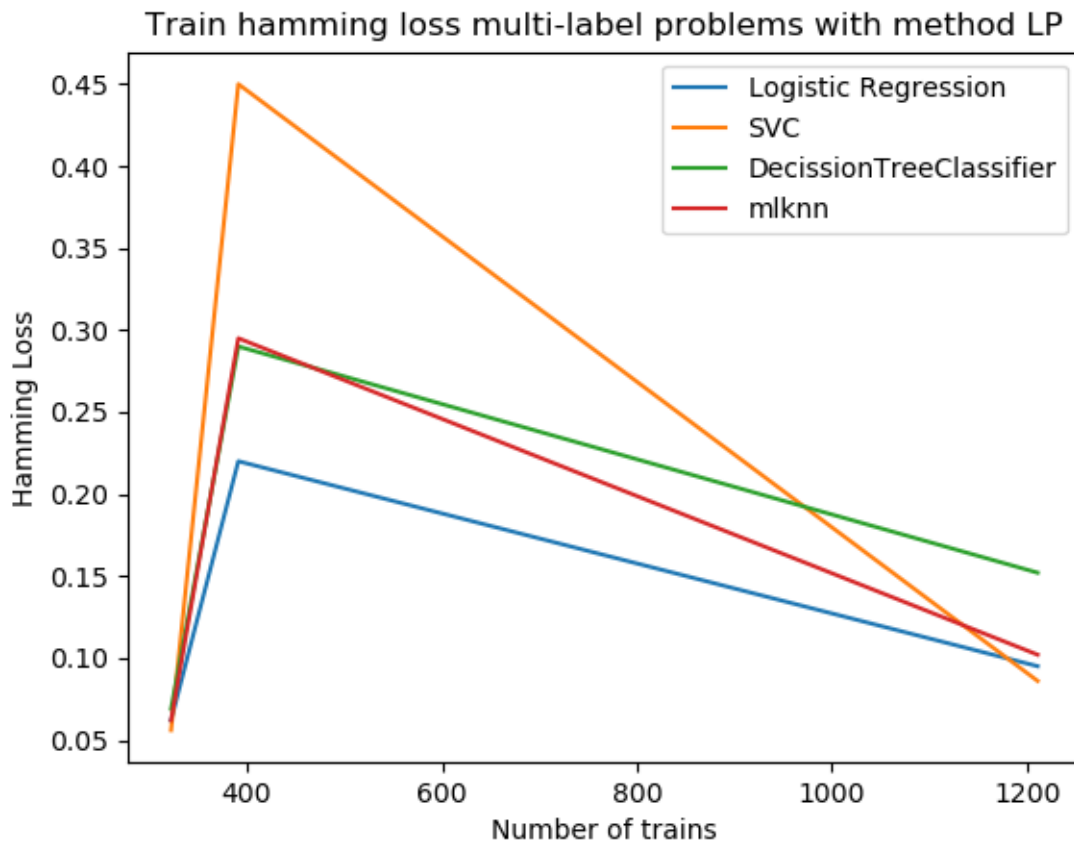
Ejercicio 5

Compare gráficamente los resultados más significativos de los ejercicios anteriores usando cualquiera de las representaciones gráficas que conozca

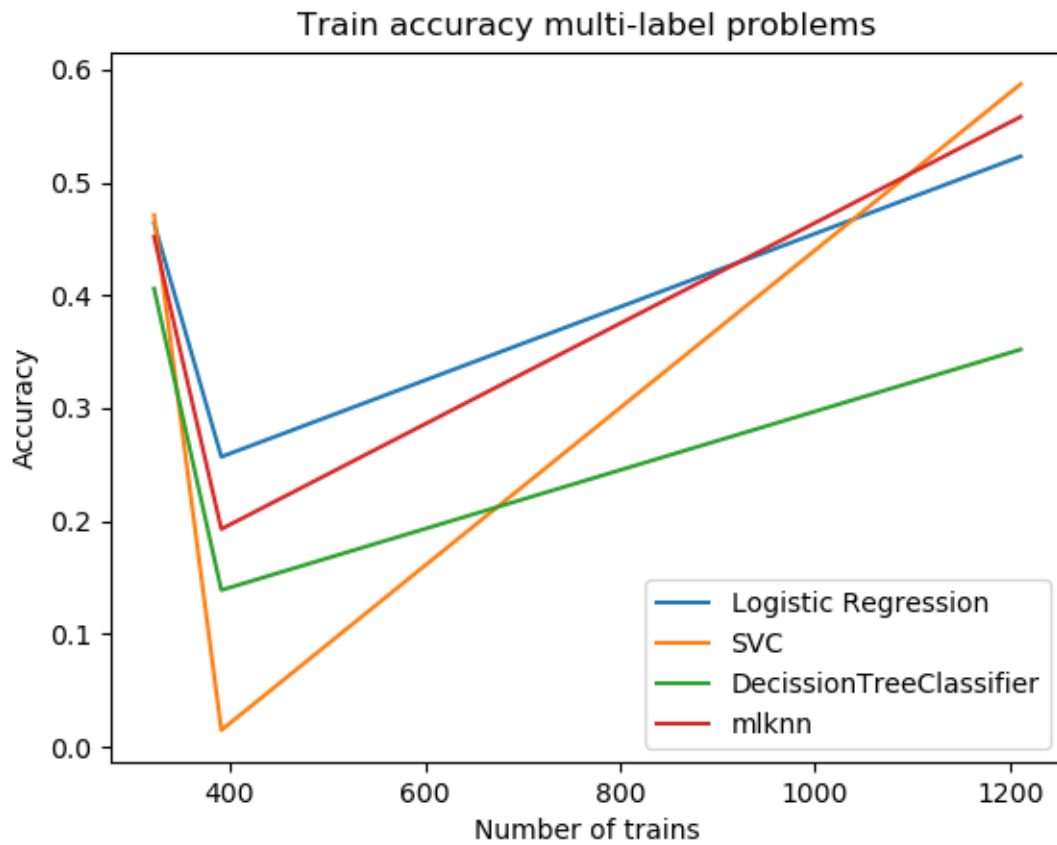
5.1. Resultados de entrenamiento



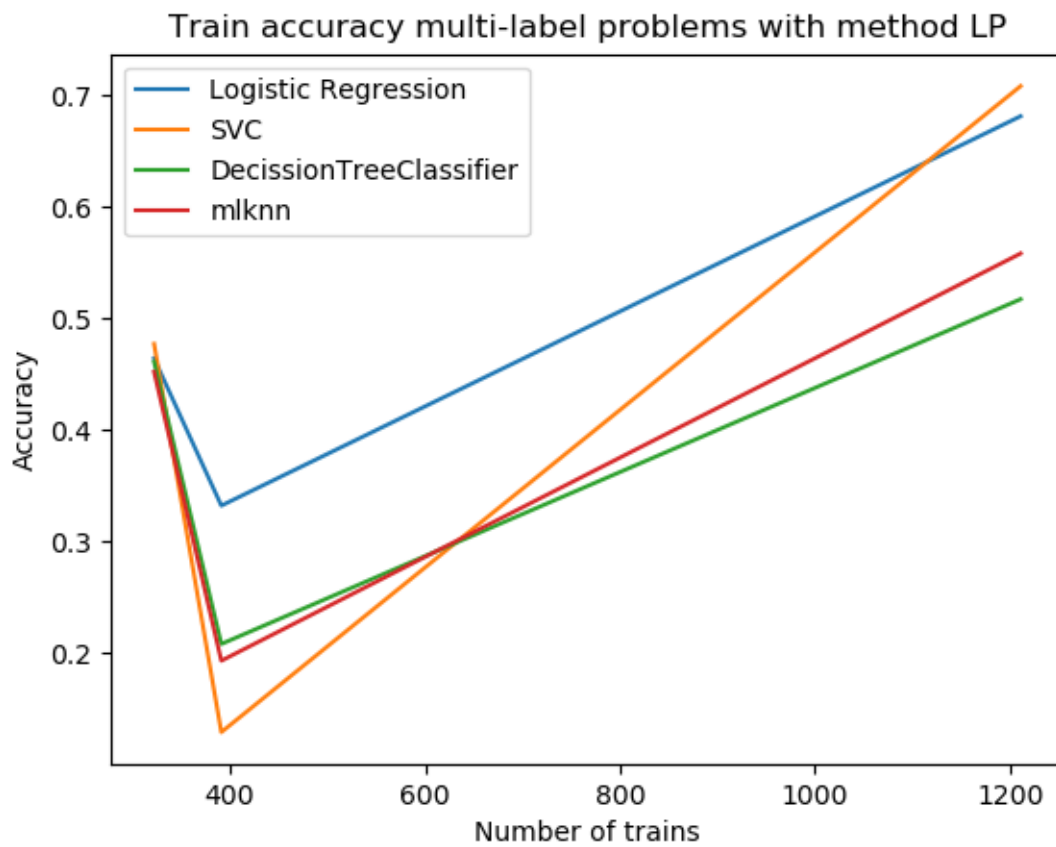
Si observamos la imagen, comprobamos que los mejores resultados se obtienen con un número de 400 entrenamientos, siendo el mejor clasificador SVC. Sin embargo, conforme aumentan el número de entrenamientos se reduce el valor de hamming loss, siendo mejor el clasificador DecisionTreeClassifier.



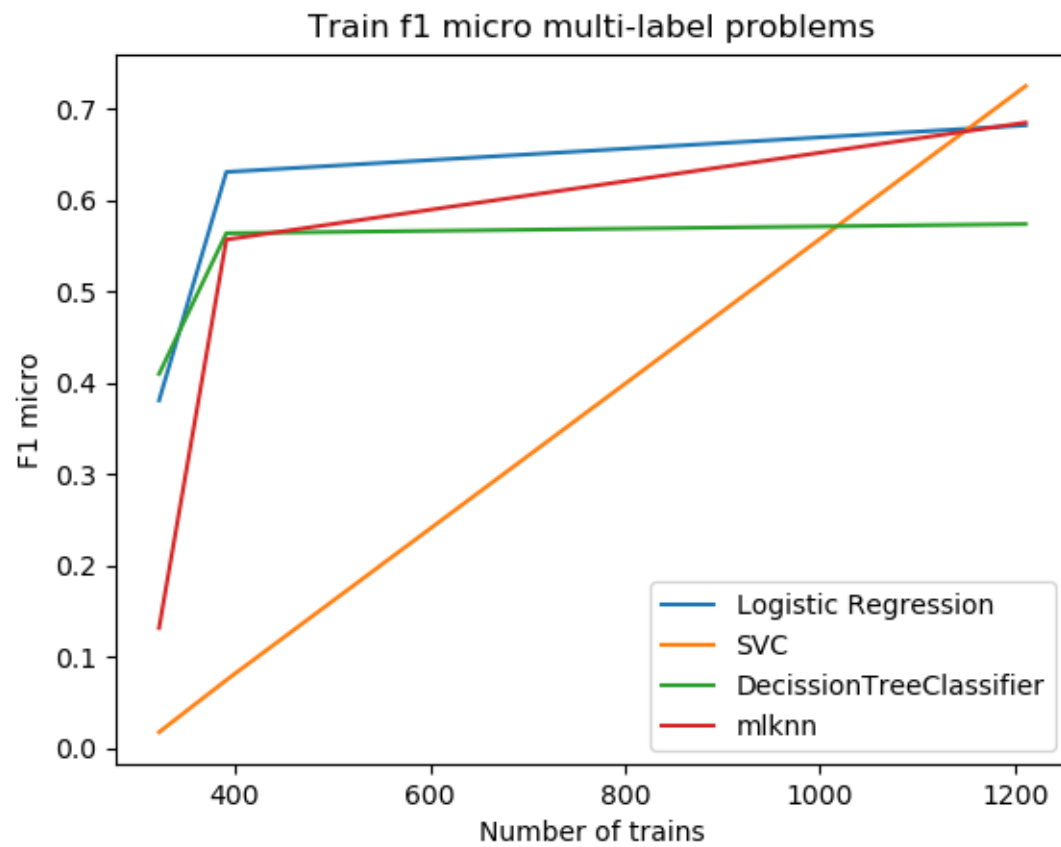
Si aplicamos el método LP, comprobamos que el valor del hamming loss mejora, pero los clasificadores se mantienen en orden de mejor a peor como en la imagen anterior. Añadiendo el clasificador MLKNN, vemos que sus resultados son similares al DecisionTreeClassifier desde los aproximadamente 400 entrenamientos, pero para un número elevado de entrenamientos esto no se mantiene.




Si observamos la gráfica, vemos que para un número menor a 400 entrenamientos, es mejor el clasificador MLKNN si tomamos la medida de ocurrencia. Sin embargo, conforme aumente el número de entrenamientos, obtiene un mayor valor de ocurrencia el clasificador SVC.



Si aplicamos el método LP, vemos que la medida de la ocurrencia es más baja para un número menor de 400 entrenamientos. Sin embargo, sigue siendo mejor el clasificador SVC.



Si observamos la gráfica, vemos que para un número de 400 entrenamientos tiene mayor medida f1 micro el clasificador Logistic Regression. Sin embargo, para un número mayor de entrenamientos, es mejor aplicar un clasificador SVC.

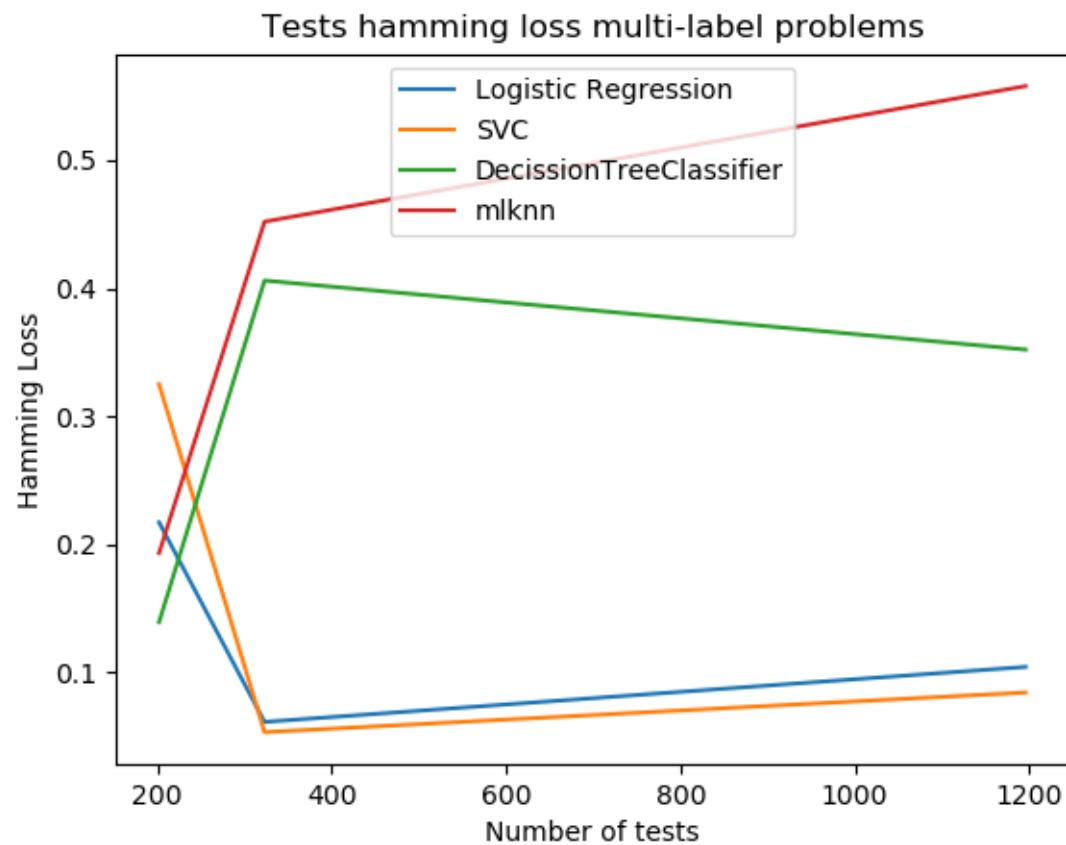


Si aplicamos el método LP, se destaca una mejora en el algoritmo SVC. Aun así, los resultados obtenidos con respecto al uso de los clasificadores son similares a los obtenidos en la gráfica anterior.


En conclusión, para un número elevado de entrenamientos elevado las medidas obtenidas nos indican que es mejor aplicar el algoritmo SVC, excepto al emplear la medida hamming loss mediante la cuál es mejor aplicar el clasificador Logistic Regression. Sin embargo, los resultados de los demás clasificadores no son desechables.

5.2. Resultados de test


A continuación, realizamos un estudio de las medidas y los algoritmos empleados en función del número de test utilizados.



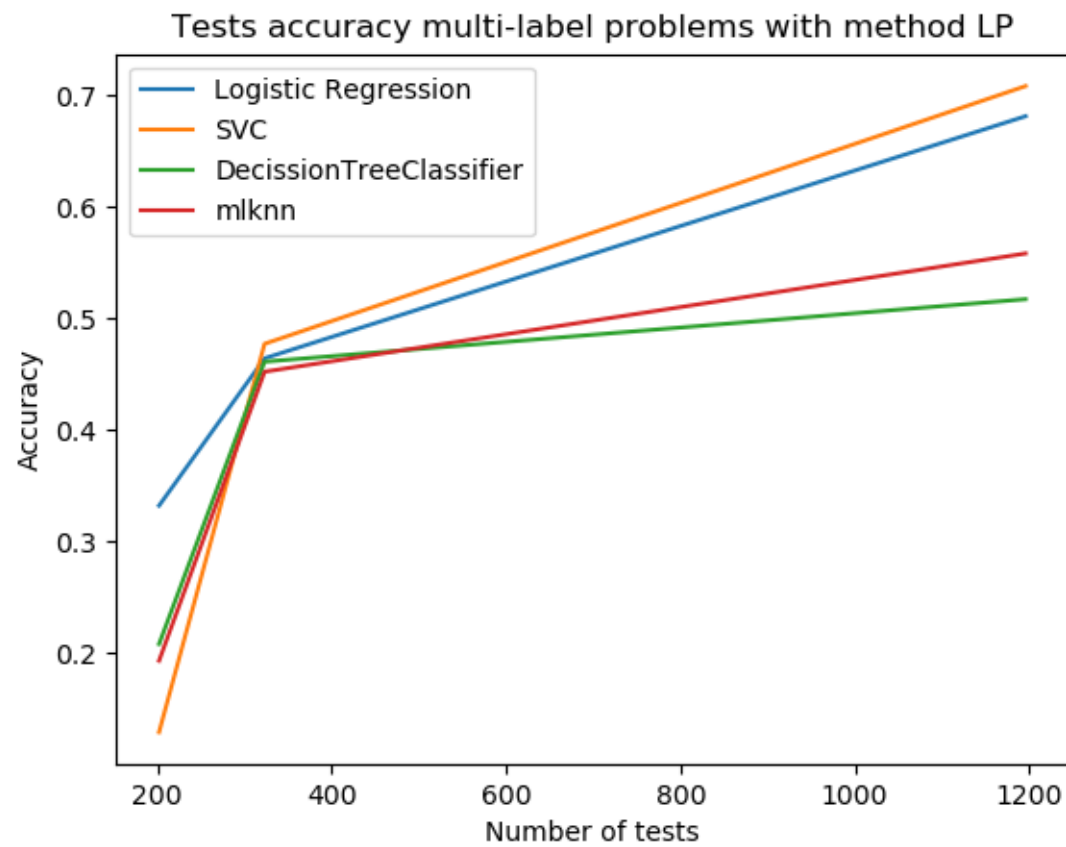
Con respecto a la medida hamming loss, vemos que tiene un valor elevado para un número inferior de test en el clasificador MLKNN, siendo dicho valor inferior al usar el clasificador SVC. Conforme aumenta el número de test, vemos que obtenemos un mejor resultado empleando el clasificador SVC.



Al aplicar el método LP, vemos que la medida hamming loss obtenida ha mejorado. Aun así, sigue siendo mejor aplicar el algoritmo SVC conforme aumenta el número de test empleado.




Si tomamos como medida de los clasificadores la ocurrencia cometida, vemos que conforme aumenta el número de test empleado es mejor utilizar el clasificador SVC.



Los valores obtenidos de la medida de la ocurrencia son similares a la gráfica anterior, observando que la ocurrencia de los clasificadores al aplicar el método LP ha mejorado.



Si observamos la gráfica, vemos que la medida f1 micro obtenida es mejor con el clasificador SVC conforme aumenta el número de test empleados.



Si aplicamos el método LP, comprobamos que la medida f1 micro de los clasificadores ha mejorado.

En conclusión, observamos que conforme aumenta el número de test empleados es mejor el clasificador SVC. Sin embargo, los resultados obtenidos por los demás clasificadores utilizados nos demuestran que dichos clasificadores no son desechables.